GUIA TECNICA COMPLETA

Forecasting de Demanda

Clasificacion de Series Temporales, Tecnicas de Pronostico
y Operacionalizacion a Escala

Documento de Referencia para Desarrollo de Modulo de Forecasting
Marzo 2026

Tabla de Contenidos

1. Introduccion y Contexto
2. Clasificacion de la Demanda: La Etapa Previa al Forecast
- 2.1 Por que clasificar antes de pronosticar
- 2.2 Esquema clasico: Clasificacion ADI-CV2 (Syntetos-Boylan)
- 2.3 Clasificaciones extendidas
- 2.4 Implementacion computacional de la clasificacion

3. Tecnicas de Forecasting por Tipo de Demanda
- 3.1 Demanda suave (Smooth)
- 3.2 Demanda erratica (Erratic)
- 3.3 Demanda intermitente (Intermittent)
- 3.4 Demanda lumpy (irregular)

4. Modelos Avanzados y Machine Learning
- 4.1 Prophet (Meta)
- 4.2 Gradient Boosting (XGBoost, LightGBM, CatBoost)
- 4.3 Redes Neuronales para Series Temporales
- 4.4 Modelos de fundacion para series temporales

5. Estrategias de Segmentacion para Forecasting
- 5.1 Segmentacion ABC por volumen/valor
- 5.2 Segmentacion ABC-XYZ
- 5.3 Segmentacion por patron de demanda
- 5.4 Segmentacion por ciclo de vida y madurez
- 5.5 Segmentacion cruzada (multidimensional)

6. Tratamiento de Outliers y Limpieza de Datos
- 6.1 Tipos de outliers en series de demanda
- 6.2 Tecnicas de deteccion de outliers
- 6.3 Estrategias de tratamiento

7. Operacionalizacion: Forecasting a Escala de Miles de SKUs
- 7.1 Arquitectura del pipeline de forecasting
- 7.2 Estrategia de seleccion automatica de modelos
- 7.3 Metricas de evaluacion
- 7.4 Consideraciones computacionales

8. Framework de Decision Integrado
- 8.1 Mapeo clasificacion a modelos candidatos

9. Aspectos Criticos Frecuentemente Subestimados
- 9.1 Calidad de datos como primer gate
- 9.2 Demanda censurada (Lost Sales)
- 9.3 Reconciliacion jerarquica
- 9.4 Gestion de productos nuevos (Cold-Start)
- 9.5 Promociones y eventos especiales
- 9.6 Canibalizacion y sustitucion
- 9.7 Gestion de overrides y factor humano
- 9.8 Granularidad temporal y su impacto
- 9.9 Monitoreo de concept drift

10. Recomendaciones para un Piloto de Forecasting
11. Stack Tecnologico Recomendado
12. Referencias y Lectura Recomendada

1. Introduccion y Contexto

El forecasting de demanda de productos es una de las disciplinas mas criticas en la gestion de cadenas de suministro, planificacion de inventarios, compras y operaciones comerciales. Un pronostico preciso permite reducir costos de almacenamiento, evitar quiebres de stock, optimizar la rotacion de inventario y mejorar el nivel de servicio al cliente.

Sin embargo, pronosticar la demanda de miles de SKUs (Stock Keeping Units) presenta desafios unicos: la heterogeneidad de patrones de demanda entre productos, la presencia de outliers, la estacionalidad variable, las promociones, los lanzamientos de nuevos productos y las discontinuidades hacen que no exista un modelo unico que funcione para todos los casos.

Esta guia aborda el problema de forma integral, cubriendo desde la etapa previa de clasificacion de la demanda (que permite decidir que tecnica aplicar a cada producto) hasta las tecnicas de pronostico propiamente dichas, los enfoques de segmentacion, el tratamiento de anomalias y la operacionalizacion computacional para generar forecasts de forma recurrente sobre catalogos masivos de productos.

> **Objetivo de este documento**
>
> Servir como referencia tecnica para el desarrollo de un modulo de forecasting que: (a) clasifique automaticamente las series de demanda, (b) seleccione y aplique el modelo mas adecuado para cada producto, (c) sea escalable a miles de SKUs, y (d) se ejecute de forma recurrente con monitoreo continuo de calidad.

2. Clasificacion de la Demanda: La Etapa Previa al Forecast

Antes de aplicar cualquier tecnica de pronostico, es fundamental entender el comportamiento de la serie temporal de cada producto. Distintos patrones de demanda requieren distintos enfoques de modelado. Esta etapa de clasificacion es lo que en la literatura se conoce como Demand Classification o Demand Pattern Recognition, y constituye el paso mas importante antes de construir el forecast.

2.1 Por que clasificar antes de pronosticar

La clasificacion previa cumple multiples propositos criticos. En primer lugar, permite seleccionar automaticamente el modelo o familia de modelos mas apropiada para cada SKU, evitando aplicar un unico enfoque que sera optimo solo para un subconjunto de productos. En segundo lugar, ahorra recursos computacionales al evitar entrenar modelos complejos donde no se justifica. Tercero, mejora la interpretabilidad del sistema al permitir que los analistas entiendan por que se eligio determinado modelo para cada producto. Finalmente, facilita el monitoreo, ya que un cambio en la clasificacion de un producto puede indicar un cambio estructural en su demanda.

2.2 Esquema clasico: Clasificacion ADI-CV2 (Syntetos-Boylan)

El esquema mas utilizado en la industria para clasificar patrones de demanda fue propuesto por Syntetos y Boylan (2005) y utiliza dos metricas calculadas directamente desde la serie temporal:

- **ADI (Average Demand Interval):** Es el intervalo promedio entre periodos con demanda no nula. Se calcula como el numero total de periodos dividido por el numero de periodos con demanda positiva. Un ADI cercano a 1 indica demanda en casi todos los periodos; un ADI alto indica demanda esporadica.
- **CV2 (Squared Coefficient of Variation):** Es la varianza de la demanda en periodos no nulos dividida por el cuadrado de la media de dicha demanda. Mide la variabilidad relativa de los tamanos de demanda cuando esta ocurre.

Combinando estos dos indicadores con umbrales tipicos (ADI = 1.32, CV2 = 0.49), se obtienen cuatro categorias fundamentales:

Categoria	ADI	CV2	Descripcion	Ejemplo tipico
Smooth (Suave)	< 1.32	< 0.49	Demanda regular y estable	Productos basicos de alto consumo
Erratic (Erratica)	< 1.32	>= 0.49	Demanda frecuente pero con tamano variable	Productos con promociones frecuentes

Intermittent (Intermitente)	>= 1.32	< 0.49	Demanda esporadica, tamano similar	Repuestos industriales
Lumpy (Irregular)	>= 1.32	>= 0.49	Esporadica y con tamano muy variable	Repuestos criticos, piezas especiales

Nota tecnica sobre los umbrales

Los valores de corte ADI = 1.32 y CV2 = 0.49 provienen del trabajo original de Syntetos y Boylan (2005) y son los mas referenciados. Sin embargo, estos umbrales pueden ajustarse segun el dominio. Algunos autores sugieren calibrarlos mediante validacion cruzada sobre el propio catalogo de productos.

2.3 Clasificaciones extendidas

El esquema ADI-CV2 es un excelente punto de partida, pero en la practica es conveniente enriquecerlo con dimensiones adicionales:

2.3.1 Deteccion de estacionalidad

Se puede aplicar un test de estacionalidad a cada serie para determinar si presenta patrones ciclicos. Las tecnicas mas comunes incluyen la descomposicion STL (Seasonal-Trend decomposition using LOESS), el test de autocorrelacion en los lags estacionales (por ejemplo, lag 12 para datos mensuales, lag 52 para datos semanales), o el test de Kruskal-Wallis sobre los periodos agrupados por estacion. Si la estacionalidad es significativa, el producto se reclasifica para recibir modelos que la capturen.

2.3.2 Deteccion de tendencia

La presencia de tendencia (creciente o decreciente) puede evaluarse mediante el test de Cox-Stuart o el test de Mann-Kendall. Productos con tendencia significativa requieren modelos que la incorporen, como Holt o Holt-Winters. Un producto en declive sostenido podria ademas requerir atencion comercial.

2.3.3 Ciclo de vida del producto

Clasificar los productos segun su etapa en el ciclo de vida (introduccion, crecimiento, madurez, declive) es util para decidir el horizonte de forecast y la confianza en las proyecciones. Productos nuevos con poca historia pueden requerir enfoques bayesianos, analogia con productos similares o juicio experto.

2.3.4 Demanda cero o producto inactivo

Productos con demanda nula o casi nula en los ultimos N periodos deben ser identificados para separarlos del proceso de forecasting activo. Estos pueden clasificarse como productos a descontinuar, obsoletos, o simplemente monitoreados con un umbral de reactivacion.

Clasificacion compuesta recomendada

Un esquema robusto para un modulo de forecasting deberia combinar: (1) la clasificacion ADI-CV2 base, (2) un flag de estacionalidad (si/no y tipo), (3) un flag de tendencia (ninguna/creciente/decreciente), (4) etapa del ciclo de vida, y (5) flag de producto inactivo. Esta clasificacion compuesta permite crear reglas de decision automatizadas para la seleccion de modelos.

2.4 Implementacion computacional de la clasificacion

Para un catalogo de miles de productos, la clasificacion debe ejecutarse de forma automatica. El flujo computacional recomendado es el siguiente:

- **Paso 1 — Extraccion:** Obtener la serie temporal de demanda de cada SKU desde el sistema transaccional (ERP, WMS, POS). Definir la granularidad temporal (diaria, semanal, mensual) y el horizonte historico minimo (se recomiendan al menos 24 periodos mensuales o equivalente).
- **Paso 2 — Preprocesamiento:** Rellenar periodos faltantes con ceros (si la ausencia de registro implica ausencia de demanda). Separar entradas de salidas si se trabaja con movimientos de inventario.
- **Paso 3 — Calculo de metricas:** Para cada SKU, calcular ADI, CV2, tests de estacionalidad y tendencia. Esto es computacionalmente liviano y puede procesarse en segundos para miles de series.
- **Paso 4 — Asignacion de categoria:** Aplicar las reglas de clasificacion y almacenar la categoria resultante junto con las metricas calculadas.
- **Paso 5 — Revision periodica:** Re-ejecutar la clasificacion periodicamente (por ejemplo, mensualmente) para detectar cambios en el comportamiento de los productos.

3. Tecnicas de Forecasting por Tipo de Demanda

Una vez clasificada la demanda de cada producto, se puede seleccionar la tecnica o familia de tecnicas mas apropiada. A continuacion se presentan las principales tecnicas organizadas segun el tipo de demanda que mejor abordan.

3.1 Demanda suave (Smooth)

Los productos con demanda regular y estable son los mas faciles de pronosticar y la mayoria de los modelos clasicos funcionan bien:

3.1.1 Suavizado exponencial simple (SES)

Es el modelo mas basico y a menudo sorprendentemente efectivo para demanda estacionaria sin tendencia ni estacionalidad. El pronostico se actualiza ponderando exponencialmente las observaciones pasadas con un parametro alpha entre 0 y 1. Un alpha cercano a 1 da mas peso a observaciones recientes; cercano a 0, mas peso al historico.

3.1.2 Holt (doble suavizado exponencial)

Extension del SES que incorpora un componente de tendencia lineal. Utiliza dos parametros de suavizado: alpha para el nivel y beta para la tendencia. Es apropiado cuando el producto muestra un crecimiento o declive sostenido.

3.1.3 Holt-Winters

Extiende el modelo de Holt anadiendo un componente estacional con parametro gamma. Puede ser aditivo (la estacionalidad tiene amplitud constante) o multiplicativo (la amplitud de la estacionalidad crece con el nivel). Es el modelo clasico de referencia para productos con estacionalidad clara.

3.1.4 ARIMA y SARIMA

Los modelos ARIMA (AutoRegressive Integrated Moving Average) ofrecen gran flexibilidad al combinar componentes autorregresivos, de diferenciacion y de media movil. SARIMA extiende ARIMA para capturar estacionalidad. La funcion auto_arima de bibliotecas como pmdarima en Python automatiza la seleccion de ordenes (p,d,q)(P,D,Q,s) mediante criterios de informacion como AIC o BIC.

3.1.5 ETS (Error, Trend, Seasonality)

El framework ETS engloba sistematicamente todas las combinaciones de tipo de error (aditivo/multiplicativo), tendencia (ninguna/aditiva/aditiva amortiguada/multiplicativa) y estacionalidad (ninguna/aditiva/multiplicativa). Produce 30 modelos posibles y la seleccion automatica se realiza por AIC. Es equivalente en muchos casos a la familia de suavizado exponencial pero con un marco estadistico formal.

Recomendacion practica para demanda Smooth

Para un sistema automatizado, ETS con seleccion automatica es una excelente opcion base. Si los datos son mensuales con estacionalidad clara, Holt-Winters multiplicativo suele funcionar muy bien. ARIMA es mas flexible pero requiere mas cuidado en la seleccion de ordenes y puede ser mas costoso computacionalmente a gran escala.

3.2 Demanda erratica (Erratic)

La demanda erratica se presenta con frecuencia pero los volumenes varian significativamente de un periodo a otro. Esto puede deberse a promociones, compras a granel, o variabilidad inherente del mercado.

- **Modelos robustos de suavizado:** Se pueden usar los mismos modelos de la seccion anterior, pero complementados con una etapa previa de limpieza de outliers y ajuste de promociones. Es fundamental separar la demanda base de los picos promocionales.
- **Regresion con variables exogenas:** Incorporar variables como indicadores de promocion, precio, dia de la semana, eventos especiales. Modelos como ARIMAX, Prophet de Meta, o regresion con features temporales permiten modelar explicitamente las causas de la variabilidad.
- **Modelos de Machine Learning:** Random Forest, Gradient Boosting (XGBoost, LightGBM) y redes neuronales pueden capturar relaciones no lineales entre las features y la demanda. Son particularmente utiles cuando se dispone de muchas variables explicativas.

3.3 Demanda intermitente (Intermittent)

La demanda intermitente es aquella donde muchos periodos tienen demanda cero y, cuando hay demanda, el volumen es relativamente constante. Es tipica de repuestos, articulos de baja rotacion y productos especializados. Los modelos convencionales funcionan mal en estos casos.

3.3.1 Metodo de Croston

Propuesto por Croston (1972), este metodo descompone el problema en dos subseries: el tamano de la demanda cuando ocurre y el intervalo entre ocurrencias. Cada subserie se pronostica por separado con suavizado exponencial simple, y el forecast final se obtiene dividiendo el tamano esperado por el intervalo esperado.

3.3.2 Syntetos-Boylan Approximation (SBA)

Es una correccion del metodo de Croston que elimina el sesgo positivo que este presenta. La correccion consiste en multiplicar el forecast de Croston por un factor (1 - alpha/2), donde alpha es el parametro de suavizado. Es el metodo recomendado sobre Croston original en la mayoria de los casos.

3.3.3 TSB (Teunter-Syntetos-Babai)

A diferencia de Croston y SBA que estiman el intervalo entre demandas, TSB estima directamente la probabilidad de demanda en cada periodo. Esto permite que la probabilidad decaiga gradualmente si pasan muchos periodos sin demanda, lo cual es util para detectar productos que se vuelven obsoletos.

3.3.4 Modelos de conteo (Poisson, Negative Binomial)

Para demanda intermitente, los modelos basados en distribuciones de conteo pueden ser mas apropiados que los modelos continuos. Un modelo Poisson o Binomial Negativo puede modelar la probabilidad de observar k unidades en un periodo. Combinados con zero-inflation (ZIP, ZINB), manejan bien el exceso de ceros.

Recomendacion para demanda intermitente

SBA (Syntetos-Boylan Approximation) es el punto de partida recomendado. Para productos donde se sospecha obsolescencia, TSB es preferible. Si se busca mayor precision y se dispone de capacidad computacional, los modelos de conteo con zero-inflation ofrecen un marco probabilistico mas rico.

3.4 Demanda lumpy (irregular)

La demanda lumpy combina lo peor de ambos mundos: es esporadica y cuando ocurre, los volumenes son muy variables. Es el patron mas dificil de pronosticar.

- **SBA como base:** Incluso para demanda lumpy, SBA ofrece un baseline razonable. Sin embargo, los intervalos de confianza seran amplios.
- **Bootstrapping de Willemain:** El metodo de Willemain et al. (2004) utiliza bootstrapping sobre los datos historicos para generar escenarios de demanda futura. En lugar de un punto de pronostico, genera una distribucion empirica de la demanda acumulada en el horizonte de planificacion. Es especialmente util para decisiones de inventario.
- **Enfoques bayesianos:** Modelos bayesianos permiten incorporar informacion a priori (por ejemplo, de productos similares) y son particularmente robustos con datos escasos. La familia de modelos Beta-Bernoulli/Gamma para combinar la decision de si habra demanda con el tamano de la demanda es un enfoque natural.
- **Agregacion temporal:** A veces, agregar la demanda en periodos mas largos (por ejemplo, pasar de semanal a mensual o trimestral) transforma una serie lumpy en intermitente o incluso erratica, permitiendo aplicar modelos mas convencionales.

4. Modelos Avanzados y Machine Learning

Mas alla de los metodos clasicos, los avances recientes en machine learning y deep learning han abierto nuevas posibilidades para el forecasting a gran escala.

4.1 Prophet (Meta)

Prophet es un modelo de descomposicion aditiva (y opcionalmente multiplicativa) que modela tendencia, estacionalidad y efectos de feriados de forma flexible. Es particularmente facil de usar, maneja bien datos faltantes y outliers, y permite incorporar conocimiento del dominio (changepoints de tendencia, estacionalidad personalizada). Su limitacion principal es que no captura dependencias autorregresivas, lo que puede limitar su precision en series con fuerte autocorrelacion de corto plazo.

4.2 Gradient Boosting (XGBoost, LightGBM, CatBoost)

Los modelos de gradient boosting se aplican al forecasting reformulando el problema como regresion tabular. Se crean features a partir de la serie temporal: lags, estadisticas moviles (medias, desviaciones estandar, min, max en ventanas), indicadores de calendario, variables ciclicas (seno y coseno para mes/semana), y cualquier variable exogena disponible. Ventajas: capturan no-linealidades, son rapidos de entrenar, y permiten analisis de importancia de variables. Desventaja: no modelan la estructura secuencial de forma nativa.

4.3 Redes Neuronales para Series Temporales

4.3.1 N-BEATS

N-BEATS (Neural Basis Expansion Analysis for Time Series) es una arquitectura de red neuronal profunda disenada especificamente para forecasting univariado. Opera mediante bloques que generan representaciones de la senal hacia atras (backcast) y hacia adelante (forecast). No requiere features adicionales y ha demostrado resultados competitivos o superiores a modelos clasicos en competencias como el M4 Competition.

4.3.2 N-HiTS

Extension de N-BEATS que incorpora submuestreo jerarquico de la serie de entrada, permitiendo capturar patrones a multiples escalas temporales de forma mas eficiente. Es particularmente bueno para horizontes de prediccion largos.

4.3.3 Temporal Fusion Transformer (TFT)

El TFT es una arquitectura basada en attention que puede incorporar variables estaticas (como categoria del producto o ubicacion del almacen), variables temporales conocidas a futuro (feriados, promociones planificadas) y variables temporales observadas (historico de demanda). Ofrece interpretabilidad a traves de pesos de atencion y feature importance integrados.

4.3.4 DeepAR

Propuesto por Amazon, DeepAR entrena un unico modelo autorregresivo basado en RNN sobre todas las series de un catalogo. Produce pronosticos probabilisticos (distribuciones completas, no solo puntos). Aprende patrones compartidos entre series similares, lo cual es muy util cuando hay muchos productos con poca historia individual.

4.4 Modelos de fundacion para series temporales

Recientemente han surgido modelos de fundacion preentrenados sobre grandes conjuntos de series temporales diversas. Modelos como TimesFM (Google), Chronos (Amazon), Moirai y TimeGPT ofrecen la posibilidad de generar pronosticos con zero-shot o fine-tuning minimo. Aunque aun es un campo en evolucion, estos modelos son prometedores para situaciones con datos historicos escasos o para obtener un baseline rapido.

Modelo	Tipo	Variables exogenas	Probabilistico	Mejor para
ETS / Auto-ARIMA	Clasico estadistico	No / ARIMAX si	Intervalos	Series individuales estables
Prophet	Descomposicion	Si (regresores)	Si	Series con estacionalidad compleja
XGBoost / LightGBM	ML tabular	Si (features)	Quantile reg.	Muchas variables exogenas
N-BEATS / N-HiTS	Deep learning	No	Ensembles	Forecasting univariado puro
TFT	Deep learning	Si (multiples tipos)	Si	Escenarios complejos con covariables
DeepAR	Deep learning	Si	Si (nativo)	Catalogos grandes con patrones cruzados
Croston / SBA / TSB	Intermitente	No	No (bootstrap si)	Demanda intermitente y lumpy
Chronos / TimesFM	Foundation model	Limitado	Si	Zero-shot, datos escasos

5. Estrategias de Segmentacion para Forecasting

La segmentacion es el proceso de agrupar productos con el fin de aplicar estrategias diferenciadas de forecasting, asignacion de recursos y nivel de atencion. No es lo mismo que la clasificacion de demanda: la segmentacion incorpora dimensiones de negocio, no solo patrones temporales.

5.1 Segmentacion ABC por volumen/valor

La segmentacion ABC clasica ordena los productos por su contribucion al volumen o valor total de ventas y los agrupa en tres categorias. Los productos A (tipicamente el 20 por ciento superior) generan alrededor del 80 por ciento del valor, los B (siguiente 30 por ciento) generan un 15 por ciento, y los C (50 por ciento restante) generan el 5 por ciento restante. Esta segmentacion determina el nivel de sofisticacion del modelo a aplicar: los productos A merecen modelos mas complejos y revision manual, mientras que los C pueden manejarse con modelos simples automatizados.

5.2 Segmentacion ABC-XYZ

Combina la clasificacion ABC (por valor o volumen) con una clasificacion XYZ basada en la predictibilidad de la demanda. Los productos X tienen demanda altamente predecible (CV bajo), los Y moderadamente predecible, y los Z impredecible. La combinacion genera una matriz de nueve celdas que permite estrategias diferenciadas:

Segmento	Valor	Predictibilidad	Estrategia de forecast
AX	Alto	Alta	Modelos sofisticados, revision frecuente, monitoreo continuo
AY	Alto	Media	Modelos con variables exogenas, alerta de desviaciones
AZ	Alto	Baja	Modelos probabilisticos, escenarios, input de expertos
BX	Medio	Alta	Modelos automaticos estandar
BY	Medio	Media	Automatizacion con revision periodica
BZ	Medio	Baja	Modelos simples con buffers de seguridad amplios
CX	Bajo	Alta	Automatizacion total, modelos simples
CY	Bajo	Media	Automatizacion total
CZ	Bajo	Baja	Considerar si vale la pena mantener el SKU

5.3 Segmentacion por patron de demanda

Usar directamente la clasificacion ADI-CV2 descrita en la seccion 2 como dimension de segmentacion permite asignar familias de modelos de forma automatica. Productos smooth reciben ETS o ARIMA, productos intermitentes reciben Croston o SBA, y asi sucesivamente.

5.4 Segmentacion por ciclo de vida y madurez

Productos nuevos (menos de 6 meses de historia), en crecimiento, maduros y en declive requieren enfoques distintos. Los nuevos pueden necesitar analogia con productos similares o tecnicas bayesianas; los maduros son candidatos ideales para modelos automaticos; los que estan en declive necesitan monitoreo de obsolescencia.

5.5 Segmentacion cruzada (multidimensional)

La segmentacion mas efectiva combina multiples dimensiones. Por ejemplo, se puede construir una matriz que cruce la clasificacion de demanda (smooth/erratic/intermittent/lumpy) con la segmentacion ABC y el ciclo de vida, generando microsegmentos con reglas de decision especificas para cada combinacion.

6. Tratamiento de Outliers y Limpieza de Datos

El tratamiento de valores atipicos es una de las etapas mas criticas y delicadas del proceso de forecasting. Un outlier no detectado puede sesgar dramaticamente un pronostico; un punto real incorrectamente clasificado como outlier puede eliminar informacion valiosa.

6.1 Tipos de outliers en series de demanda

- **Outliers aditivos (AO):** Afectan un unico punto en el tiempo. Son picos o caidas aisladas. Ejemplo: un error de registro, una venta unica a un cliente que no es habitual.
- **Cambios de nivel (Level Shift, LS):** El nivel medio de la serie cambia a partir de un punto. Ejemplo: un nuevo cliente empieza a comprar regularmente, o se pierde un canal de venta.
- **Cambios transitorios (TC):** Un pico o caida que se disipa gradualmente a lo largo de varios periodos. Ejemplo: efecto de una promocion que eleva la demanda y luego decae.
- **Outliers innovativos (IO):** Afectan la serie a traves de su estructura autorregresiva, propagandose a periodos futuros.

6.2 Tecnicas de deteccion de outliers

6.2.1 Metodos estadisticos clasicos

- **IQR (Rango Intercuartilico):** Valores fuera de [Q1 - 1.5*IQR, Q3 + 1.5*IQR] se marcan como outliers. Simple y rapido, pero no considera la estructura temporal.
- **Z-score:** Valores con |z| > 3 (o un umbral elegido) se consideran atipicos. Asume normalidad.
- **Descomposicion STL + residuos:** Se descompone la serie en tendencia, estacionalidad y residuo. Los outliers se buscan en el componente residual usando IQR o z-score. Tiene la ventaja de que respeta la estructura temporal.

6.2.2 Metodos basados en modelos

- **TSOUTLIERS (paquete R):** Ajusta un modelo ARIMA y busca los cuatro tipos de outliers (AO, LS, TC, IO) de forma iterativa. Es el enfoque mas completo para deteccion en series temporales.
- **Hampel filter:** Usa medianas moviles y MAD (Median Absolute Deviation) para detectar outliers de forma robusta a lo largo de la serie.
- **Isolation Forest:** Metodo de machine learning que detecta anomalias aislando puntos en arboles aleatorios. Util cuando se tienen multiples features.

6.3 Estrategias de tratamiento

Una vez detectados los outliers, existen varias estrategias de tratamiento:

- **Reemplazo por interpolacion:** Sustituir el valor atipico por la media o mediana de los valores vecinos, o por interpolacion lineal. Es simple pero puede eliminar informacion util.
- **Winsorización:** Limitar los valores extremos a un percentil definido (por ejemplo, el 95). Menos agresivo que eliminar.
- **Imputacion basada en modelo:** Usar el valor ajustado (fitted value) del modelo de series temporales como reemplazo. Mantiene la coherencia con la estructura temporal.
- **Mantencion con flag:** Mantener el valor original pero marcarlo, y usar modelos robustos que reduzcan su influencia. Esto permite preservar la informacion para analisis posterior.

Principio guia para outliers

Siempre es preferible entender la causa del outlier antes de decidir su tratamiento. Si el outlier corresponde a una promocion, debe modelarse como tal (no eliminarse). Si es un error de registro, debe corregirse. Si es una compra unica improbable de repetirse, debe atenuarse. La automatizacion del tratamiento de outliers debe incluir reglas de negocio, no solo reglas estadisticas.

7. Operacionalizacion: Forecasting a Escala de Miles de SKUs

Uno de los mayores desafios practicos es pasar de un modelo que funciona bien para un producto individual a un sistema que genera forecasts confiables para miles de productos de forma recurrente, eficiente y monitoreada.

7.1 Arquitectura del pipeline de forecasting

Un pipeline de forecasting robusto consta de las siguientes etapas ejecutadas de forma secuencial:

- **1. Ingesta de datos:** Extraccion automatizada de datos de demanda desde los sistemas fuente (ERP, WMS, POS, bases de datos). Incluye validacion de completitud y calidad basica.
- **2. Preprocesamiento:** Imputacion de faltantes, alineacion temporal, conversion de unidades si es necesario, y creacion de la serie temporal limpia para cada SKU.
- **3. Clasificacion de demanda:** Ejecucion de las metricas de clasificacion (ADI, CV2, tests de estacionalidad y tendencia) y asignacion de categoria a cada producto.
- **4. Deteccion y tratamiento de outliers:** Aplicacion de los metodos de deteccion y las reglas de tratamiento definidas para cada segmento.
- **5. Seleccion y ajuste de modelos:** Basado en la clasificacion y segmentacion, se selecciona el modelo (o modelos candidatos) para cada SKU. Se ajustan los parametros, opcionalmente mediante grid search o optimizacion bayesiana.
- **6. Generacion de pronosticos:** Se produce el forecast puntual y los intervalos de confianza para el horizonte definido.
- **7. Evaluacion y monitoreo:** Se calculan metricas de error (MAE, MAPE, RMSE, sesgo) y se comparan con umbrales predefinidos. Se generan alertas para productos cuyo forecast se degrade.
- **8. Almacenamiento y distribucion:** Los forecasts se almacenan en una base de datos y se distribuyen a los sistemas consumidores (planificacion, compras, logistica).

7.2 Estrategia de seleccion automatica de modelos

Para automatizar la seleccion de modelos en un catalogo masivo, se recomienda una estrategia de competencia de modelos (model horse-race). Para cada SKU o grupo de SKUs se entrena un conjunto de modelos candidatos (definidos por la clasificacion de demanda), se evaluan en una ventana de validacion (backtest), y se selecciona el que minimiza una metrica de error predefinida. Este proceso puede ejecutarse menos frecuentemente que la generacion de forecasts (por ejemplo, mensualmente) para reducir el costo computacional.

7.3 Metricas de evaluacion

Metrica	Formula conceptual	Ventajas	Limitaciones
MAE	Media de |real - forecast|	Interpretable en unidades originales	No penaliza errores grandes desproporcionadamente
RMSE	Raiz de la media de (real - forecast)^2	Penaliza errores grandes	Sensible a outliers en la evaluacion
MAPE	Media de |error| / |real| * 100	Comparable entre productos	Indefinido cuando real = 0 (demanda intermitente)
WAPE / WMAPE	Suma |errores| / Suma |reales|	Maneja ceros, ponderado por volumen	Sesgado hacia periodos de alta demanda
Sesgo (Bias)	Media de (forecast - real)	Detecta sobre/sub-estimacion sistematica	No mide magnitud del error
MASE	MAE / MAE de naive estacional	Escalable, comparativo, maneja ceros	Requiere calcular el baseline naive

Metrica recomendada para demanda intermitente

Para productos con demanda intermitente, el MAPE es inutilizable por los ceros en el denominador. El MASE (Mean Absolute Scaled Error) propuesto por Hyndman y Koehler (2006) es la metrica recomendada ya que esta bien definida para todos los patrones de demanda y permite comparacion entre series con escalas diferentes.

7.4 Consideraciones computacionales

7.4.1 Paralelismo y distribucion

El forecasting de miles de SKUs es un problema naturalmente paralelizable, ya que cada serie puede procesarse de forma independiente. Se recomienda usar procesamiento paralelo (multiprocessing en Python, o distribucion con frameworks como Dask, Ray o Spark). Un catalogo de 10,000 SKUs con modelos clasicos (ETS, ARIMA) puede procesarse en minutos con paralelismo adecuado en una maquina moderna.

7.4.2 Frameworks especializados

Existen frameworks de Python disenados especificamente para forecasting a escala:

- **StatsForecast (Nixtla):** Implementaciones ultraoptimizadas de modelos clasicos (ETS, ARIMA, Theta, Croston, SBA) escritas en C/Numba. Puede procesar cientos de miles de series en minutos. Es la opcion recomendada para modelos clasicos a escala.
- **MLForecast (Nixtla):** Framework para aplicar modelos de ML (XGBoost, LightGBM, etc.) a forecasting con creacion automatica de features temporales. Integra con StatsForecast.

- **NeuralForecast (Nixtla):** Implementaciones de N-BEATS, N-HiTS, TFT, DeepAR y otros modelos de deep learning para series temporales. Permite entrenar un unico modelo sobre multiples series (global model).
- **Darts (Unit8):** Framework unificado que integra modelos clasicos, ML y deep learning bajo una API comun. Excelente para prototipado y comparacion de modelos.
- **GluonTS (Amazon):** Framework de deep learning probabilistico para series temporales. Incluye DeepAR y otros modelos.

7.4.3 Estrategia de ejecucion recurrente

Un modulo de forecasting en produccion tipicamente se ejecuta de forma periodica (diaria, semanal o mensual, dependiendo de la granularidad). La ejecucion recurrente incluye: actualizacion de datos, re-evaluacion de clasificacion (menos frecuente), re-ajuste de modelos (periodico o disparado por degradacion), generacion de pronosticos, calculo de metricas, generacion de alertas, y almacenamiento de resultados. Todo esto debe ser orquestado por un scheduler (cron, Airflow, Prefect, Dagster) con manejo de errores, logging y notificaciones.

8. Framework de Decision Integrado

A continuacion se presenta un framework de decision que integra todos los conceptos anteriores en un flujo logico para determinar que modelo aplicar a cada producto:

Paso	Accion	Resultado
1	Calcular ADI y CV2 de la serie	Categoria base: Smooth, Erratic, Intermittent, Lumpy
2	Aplicar tests de estacionalidad y tendencia	Flags: estacional (si/no), tendencia (si/no/tipo)
3	Evaluar longitud del historico	Flag: suficiente (>= 24 per.) / insuficiente
4	Clasificar ciclo de vida	Etapa: nuevo, crecimiento, maduro, declive, inactivo
5	Asignar segmento ABC-XYZ	Prioridad y nivel de sofisticacion
6	Seleccionar modelos candidatos segun reglas	Lista de modelos a competir
7	Ejecutar backtest con modelos candidatos	Metrica de error para cada modelo
8	Seleccionar mejor modelo	Modelo ganador + metrica asociada
9	Generar forecast y almacenar	Pronostico + intervalos + metadata
10	Monitorear y re-evaluar periodicamente	Alertas de degradacion, reclasificacion

8.1 Mapeo clasificacion a modelos candidatos

Clasificacion	Modelos candidatos recomendados
Smooth sin estacionalidad	SES, Holt (si tendencia), ETS auto, ARIMA auto
Smooth con estacionalidad	Holt-Winters, SARIMA, ETS auto, Prophet, STL + ETS
Erratic sin exogenas	ETS auto, ARIMA auto, Theta, mediana movil robusta
Erratic con exogenas	Prophet, ARIMAX, XGBoost/LightGBM, TFT
Intermittent	SBA (Croston corregido), TSB, modelos de conteo (Poisson/NB)
Lumpy	SBA, Willemain bootstrap, ADIDA (agregacion temporal), bayesiano
Nuevo producto (< 6 meses)	Analogia, bayesiano con prior informativo, media de cluster similar
Producto inactivo	No forecasting activo; monitoreo de reactivacion

9. Aspectos Criticos Frecuentemente Subestimados

Mas alla de los modelos y las tecnicas, existen aspectos operacionales y de negocio que determinan el exito o fracaso de un sistema de forecasting en produccion. Estos temas suelen subestimarse en la etapa de diseno y terminan siendo las principales causas de falla o desconfianza del sistema.

9.1 Calidad de datos como primer gate

Antes de clasificar y antes de modelar, el pipeline debe incluir un modulo de calidad de datos que actue como primera barrera. La mayoria de los errores de forecast que se reportan en produccion no son errores de modelo sino errores de datos. Este modulo debe detectar registros duplicados, cambios silenciosos de unidad de medida (por ejemplo, un producto que pasa de venderse en unidades a venderse en cajas sin que el sistema lo registre), series con gaps inexplicables que no corresponden a quiebre de stock, cambios bruscos en volumenes por migracion de sistemas ERP, y codigos de producto reasignados o fusionados.

La recomendacion es implementar un conjunto de reglas de validacion que se ejecuten antes de cualquier proceso analitico. Cada SKU debe pasar por este gate y recibir un score de calidad. Los productos con score bajo deben ser excluidos del forecasting automatico y derivados a revision manual o a un flujo de limpieza especifico.

9.2 Demanda censurada (Lost Sales)

Cuando un producto tiene quiebre de stock, la demanda observada es cero (o muy baja), pero la demanda real no lo era: simplemente no pudo materializarse porque no habia producto disponible. Si el modelo se entrena con estos ceros de quiebre, sistematicamente subestimara la demanda futura, generando un ciclo vicioso donde el quiebre se perpetua.

Para abordar este problema se necesita cruzar la serie de demanda con la informacion de disponibilidad de inventario. Los periodos donde el stock fue cero o estuvo por debajo de un umbral minimo deben marcarse como censurados. Luego, existen varias estrategias: excluir esos periodos del entrenamiento, imputar la demanda latente usando el promedio de periodos equivalentes con stock disponible, o usar modelos de censura (como Tobit) que manejan explicitamente la truncacion. La estrategia mas pragmatica para un primer piloto es simplemente excluir los periodos de stockout y documentar cuantos SKUs se ven afectados.

Impacto practico de la demanda censurada

En catalogos con niveles de servicio inferiores al 95%, la proporcion de series afectadas por censura puede superar el 30%. Ignorar este efecto genera un sesgo negativo sistematico que no se corrige con modelos mas sofisticados, ya que el problema esta en los datos, no en el algoritmo.

9.3 Reconciliacion jerarquica

En cualquier organizacion con estructura de productos (SKU, subcategoria, categoria, linea de negocio) o estructura geografica (tienda, region, pais), los forecasts generados a nivel granular (SKU) rara vez suman exactamente lo que se pronostica a nivel agregado. Esta incoherencia genera desconfianza inmediata del negocio: si el forecast total de la categoria no cuadra con la suma de los forecasts de sus SKUs, el planner pierde confianza en el sistema.

La reconciliacion jerarquica es el proceso de ajustar los forecasts en todos los niveles para que sean coherentes. Las principales tecnicas son:

- **Bottom-Up:** Se pronostica a nivel SKU y se agrega hacia arriba. Simple pero pierde la posibilidad de capturar patrones que solo son visibles a nivel agregado.
- **Top-Down:** Se pronostica a nivel agregado y se distribuye hacia abajo usando proporciones historicas. Pierde la granularidad de cada SKU.
- **Middle-Out:** Se pronostica en un nivel intermedio y se reconcilia hacia arriba y hacia abajo.
- **MinTrace (optimo):** Metodo propuesto por Wickramasuriya et al. (2019) que genera forecasts en todos los niveles y luego los reconcilia minimizando el error de traza de la matriz de covarianza. Es el metodo mas robusto y recomendado. Disponible en la libreria HierarchicalForecast de Nixtla.

La recomendacion es incorporar reconciliacion jerarquica desde la Fase 2 del piloto, no dejarlo para la Fase 3. Los stakeholders de negocio interactuan con niveles agregados y la coherencia es un requisito basico de credibilidad.

9.4 Gestion de productos nuevos (Cold-Start)

Los productos nuevos representan un desafio particular porque no tienen historia suficiente para aplicar modelos estadisticos convencionales. Sin embargo, en muchos catalogos la rotacion de SKUs es alta (lanzamientos, variantes, formatos nuevos), por lo que no es un caso marginal sino una necesidad central.

La estrategia recomendada se basa en tres etapas:

- **Etapa 1 - Analogia por cluster (semanas 0-8):** Antes de tener datos, se asigna el producto a un cluster de productos similares basado en atributos como categoria, subcategoria, rango de precio, formato, canal de venta. El forecast se toma de la curva promedio del cluster, opcionalmente escalada por un factor de expectativa del equipo comercial.
- **Etapa 2 - Transicion bayesiana (semanas 8-24):** A medida que se acumulan datos reales del producto nuevo, se usa un enfoque bayesiano donde el prior es la curva del cluster y la evidencia es la demanda observada. Gradualmente, el peso del prior disminuye y los datos propios dominan el forecast.

- **Etapa 3 - Modelo individual (semana 24+):** Una vez que el producto tiene suficiente historia (tipicamente 6 meses o mas), pasa al flujo estandar de clasificacion ADI-CV2 y seleccion automatica de modelos.

Para implementar esto, se necesita mantener un catalogo de clusters con sus curvas tipicas de lanzamiento actualizadas, y un mecanismo para asignar automaticamente nuevos SKUs a un cluster basado en sus atributos.

9.5 Promociones y eventos especiales

Las promociones son una de las fuentes de variabilidad mas importantes en la demanda de productos de consumo y retail. Un sistema de forecasting que no separe la demanda base de la demanda promocional (uplift) tendra problemas sistematicos: sobreestimara en periodos sin promocion (porque el modelo aprendio con datos inflados) y subestimara en periodos con promocion (porque promedia el efecto).

El tratamiento correcto requiere tres componentes: primero, un calendario historico de promociones por SKU (tipo de promocion, descuento aplicado, canal, duracion) para limpiar el historico y estimar el uplift. Segundo, un calendario futuro de promociones planificadas para incorporar el efecto esperado en el forecast. Tercero, un modelo de uplift que estime el incremento porcentual de demanda segun el tipo de promocion, el descuento y el producto. Este modelo puede ser tan simple como un factor multiplicador promedio por tipo de promocion, o tan sofisticado como un modelo de ML con features de producto y promocion.

> **Separacion baseline vs. uplift**
> La practica recomendada es construir primero un forecast de demanda base (baseline) excluyendo o ajustando los periodos promocionales, y luego sumar el uplift esperado para los periodos donde se planifica una promocion. Esto permite que el modelo base sea mas estable y que el efecto promocional se gestione de forma independiente.

9.6 Canibalizacion y sustitucion

La canibalizacion ocurre cuando la promocion o lanzamiento de un producto reduce la demanda de otro producto relacionado. La sustitucion ocurre cuando un producto en quiebre de stock transfiere su demanda a un producto alternativo. Ambos efectos hacen que los forecasts individuales de SKUs sean correctos de forma aislada pero incorrectos en conjunto.

Detectar estos efectos requiere analizar correlaciones cruzadas entre series de productos dentro de la misma categoria o subcategoria. Si el incremento de demanda de un producto coincide sistematicamente con la caida de otro, existe una relacion de canibalizacion o sustitucion. En la practica, para un primer piloto basta con documentar estos pares de productos y ajustar manualmente. Para un sistema maduro, se pueden usar modelos VAR (Vector AutoRegression) o modelos de demanda conjunta que capturen estas interdependencias.

9.7 Gestion de overrides y factor humano

Ningun sistema de forecasting en produccion funciona sin la posibilidad de que un analista o demand planner sobreescriba el pronostico generado automaticamente. Los overrides son necesarios cuando el sistema no tiene acceso a informacion que el humano si posee: un cliente grande que confirmo un pedido excepcional, un evento de mercado no capturado en los datos, o un problema de calidad que afectara las ventas.

Sin embargo, la evidencia empirica muestra que en muchas organizaciones los overrides degradan la calidad del forecast mas de lo que la mejoran. Esto ocurre porque se aplican sin criterio, sin medicion, y sin accountability. Para evitar este problema, el sistema debe implementar:

- **Trazabilidad completa:** Registrar quien hizo el override, cuando, sobre que SKU, el valor original del sistema, el valor modificado, y la justificacion.
- **Medicion comparativa:** Calcular el error del forecast con y sin override para cada SKU y cada planner. Esto permite identificar si los overrides estan agregando o destruyendo valor.
- **Reglas de gobernanza:** Definir quien puede hacer overrides, en que segmentos (tipicamente solo productos A), y con que limites (por ejemplo, no modificar mas del 30% del valor del sistema sin aprobacion de un supervisor).
- **Feedback al planner:** Mostrar al planner su track record historico de overrides: en cuantos casos mejoro el forecast, en cuantos lo empeoro, y cual es su sesgo promedio.

9.8 Granularidad temporal y su impacto

La decision de trabajar con datos diarios, semanales o mensuales afecta profundamente todo el pipeline y no es trivial. Datos diarios contienen mas ruido, mas ceros (un producto con demanda mensual smooth puede parecer intermitente a nivel diario), y requieren modelos que manejen efectos de dia de semana. Datos mensuales son mas suaves pero pierden patrones intra-mes relevantes para reposicion y pueden ocultar estacionalidad semanal.

La granularidad debe definirse segun el caso de uso principal del forecast. Si el objetivo es reposicion en tiendas, se necesita granularidad diaria o semanal. Si el objetivo es planificacion de compras a proveedores, mensual puede ser suficiente. Si existen multiples consumidores del forecast, se recomienda generar a la granularidad mas fina posible y agregar segun necesidad, aplicando reconciliacion temporal para asegurar coherencia.

9.9 Monitoreo de concept drift

Los modelos de forecasting se entrenan con datos historicos bajo el supuesto implicito de que los patrones del pasado se mantendran en el futuro. Cuando la distribucion de la demanda cambia estructuralmente (concept drift), el modelo deja de ser valido aunque sus metricas de entrenamiento hayan sido buenas. Ejemplos de drift incluyen: un cambio en el mix de canales de

venta, la entrada de un competidor, un cambio regulatorio, o una tendencia de mercado que se acelera o desacelera.

No basta con monitorear metricas de error agregadas: se necesita un mecanismo que detecte cuando el error de un SKU supera umbrales predefinidos de forma sostenida y dispare automaticamente un re-entrenamiento o una reclasificacion. Tecnicas como ADWIN (Adaptive Windowing), Page-Hinkley Test, o simplemente reglas basadas en CUSUM (suma acumulada de errores) permiten detectar drift de forma automatizada. El sistema debe distinguir entre un spike puntual (que puede ser un outlier) y un cambio persistente que requiere accion.

Regla practica para deteccion de drift

Una implementacion simple pero efectiva consiste en mantener una ventana movil del error (por ejemplo, las ultimas 4 semanas) y compararla con la distribucion historica del error. Si el error reciente supera el percentil 95 de la distribucion historica durante 3 o mas periodos consecutivos, se marca el SKU para re-entrenamiento automatico y se genera una alerta al equipo.

10. Recomendaciones para un Piloto de Forecasting

Si el objetivo es implementar un piloto para luego desarrollar el modulo completo, se recomienda seguir una estrategia incremental:

10.1 Fase 1: Fundamentos (semanas 1-3)

- Seleccionar un subconjunto representativo de 50-200 SKUs que cubra las principales categorias de demanda.
- Implementar la clasificacion ADI-CV2 y los tests de estacionalidad/tendencia.
- Implementar deteccion basica de outliers (STL + IQR o Hampel).
- Aplicar ETS automatico (para smooth/erratic) y SBA (para intermitente/lumpy) como modelos base.
- Calcular metricas de error con backtest de al menos 3 horizontes.
- Documentar los resultados y validarlos con el equipo de negocio.

10.2 Fase 2: Expansion (semanas 4-6)

- Ampliar a todo el catalogo de productos.
- Implementar la competencia de modelos: agregar ARIMA, Prophet, y al menos un modelo de ML (XGBoost).
- Implementar la segmentacion ABC-XYZ para priorizar atencion.
- Desarrollar el pipeline automatizado con orquestacion basica.
- Implementar monitoreo de calidad y alertas.

10.3 Fase 3: Sofisticacion (semanas 7-10)

- Incorporar variables exogenas donde esten disponibles (promociones, precios, eventos).
- Evaluar modelos de deep learning para los segmentos de mayor valor (DeepAR, TFT).
- Implementar reconciliacion jerarquica si hay estructura de producto (categoria > subcategoria > SKU).
- Refinar reglas de negocio para outliers y excepciones.
- Generar dashboards de monitoreo para el equipo.

10.4 Fase 4: Produccion (semanas 11+)

- Poner el sistema en produccion con ejecucion recurrente automatizada.
- Implementar feedback loop: los resultados reales se comparan con los pronosticos y alimentan el modelo.

- Establecer gobernanza: roles (quien revisa forecasts A, quien aprueba overrides), SLAs, documentacion.
- Iterar continuamente: agregar nuevos modelos, refinar clasificacion, mejorar features.

11. Stack Tecnologico Recomendado

Componente	Opcion recomendada	Alternativas
Lenguaje	Python 3.10+	R (si el equipo lo domina)
Modelos clasicos	StatsForecast (Nixtla)	statsmodels, sktime, fable (R)
Modelos ML	MLForecast + LightGBM	XGBoost, CatBoost, scikit-learn
Modelos DL	NeuralForecast (Nixtla)	PyTorch Forecasting, GluonTS, Darts
Feature engineering	tsfresh, featuretools	tsfel, custom pipelines
Deteccion outliers	tsoutliers (R) o pyod (Python)	Isolation Forest, STL manual
Orquestacion	Airflow o Prefect	Dagster, cron, Luigi
Almacenamiento	PostgreSQL / TimescaleDB	BigQuery, Snowflake, ClickHouse
Monitoreo	MLflow + dashboards (Grafana)	Weights & Biases, custom
Visualizacion	Plotly / Streamlit	Dash, Panel, Superset

12. Referencias y Lectura Recomendada

12.1 Libros fundamentales

- Hyndman, R.J. y Athanasopoulos, G. (2021). Forecasting: Principles and Practice, 3ra edicion. Disponible gratuitamente en otexts.com/fpp3. Es la referencia mas completa y accesible sobre forecasting moderno.
- Ord, K., Fildes, R., y Kourentzes, N. (2017). Principles of Business Forecasting, 2da edicion. Enfoque orientado a negocio.
- Syntetos, A.A., Boylan, J.E., y Croston, J.D. (2005). On the categorization of demand patterns. Journal of the Operational Research Society, 56(5), pp.495-503.

12.2 Articulos clave

- Croston, J.D. (1972). Forecasting and Stock Control for Intermittent Demands. El trabajo seminal sobre forecasting de demanda intermitente.
- Syntetos, A.A. y Boylan, J.E. (2005). The accuracy of intermittent demand estimates. Propuesta del metodo SBA.
- Hyndman, R.J. y Koehler, A.B. (2006). Another look at measures of forecast accuracy. Propuesta del MASE.
- Willemain, T.R. et al. (2004). A new approach to forecasting intermittent demand for service parts inventories. Metodo de bootstrapping.

12.3 Recursos tecnicos

- Documentacion de StatsForecast: nixtla.github.io/statsforecast. Ejemplos y benchmarks.
- Documentacion de NeuralForecast: nixtla.github.io/neuralforecast. Modelos de deep learning para series temporales.
- Documentacion de Darts: unit8co.github.io/darts. Framework unificado.
- M5 Competition (2020): competencia de forecasting de Walmart que produjo muchos insights sobre forecasting jerarquico a gran escala.

Fin del documento